Classificação de Imagens de Tecido de Mama

Aurélio Gabriel Ortiz Vieira
UFPR
Curitiba, Brazil

Gustavo Benitez Frehse
UFPR
Curitiba, Brazil

Resumo

Este projeto apresenta uma análise do desempenho de classificadores para imagens de tecido mamário, com o objetivo de distinguir lesões benignas e malignas. Foram avaliados os modelos SVM e Random Forest a partir de características de técnicas radiômicas e ResNet50, além da junção dessas características, resultando em seis configurações distintas de análise. Os resultados indicam que o SVM utilizando o vetor de características mesclado apresentou o melhor desempenho entre as abordagens testadas.

1 Introdução

Algoritmos de aprendizado de máquina são modelos computacionais capazes de identificar padrões e prever resultados a partir do treinamento em um conjunto de dados. O uso dessa tecnologia na classificação de imagens biomédicas auxilia na predição e no diagnóstico de anomalias, otimizando o tempo de análise e tornando o processo de decisão dos profissionais de saúde mais eficiente.

Para demonstrar a eficácia da classificação por modelos computacionais, esta pesquisa avalia dois algoritmos: SVM (Support Vector Machine) e Random Forest. Ambos foram treinados por meio da extração de características pela CNN ResNet50 e por técnicas de radiômica, aplicadas a 1.318 imagens de tecido mamário, classificadas como benignas ou malignas.

2 Métodos

Para identificar a melhor combinação entre diferentes extratores de características e dois modelos preditivos, implementou-se um *pipeline* automatizado em Python (disponível no GitHub), composto pelas seguintes etapas de classificação e previsão:

(1) Preparação da base de dados CBIS-DDSM
(2) Extração de características utilizando *ResNet50* e a técnica radiômica do *pyradiomics*;
(3) Junção das características em um vetor único;
(4) Treinamento e avaliação dos modelos *SVM* e *Random Forest* utilizando três conjuntos distintos: características isoladas da *ResNet50*, características isoladas da radiômica e o vetor com ambos;
(5) Armazenamento das métricas de desempenho/eficiência dos modelos.

2.1 Dataset

A base de dados utilizada no *pipeline* foi a *CBIS-DDSM: Breast Cancer Image Dataset* (disponível no Kaggle). Este conjunto de dados contém exames de mamografia digital formatados em imagens médicas, acompanhados por planilhas (*csv*) de metadados clínicos.

As imagens abrangem as mamografias categorizadas entre achados de massas tumorais e calcificações. Além das imagens mamográficas completas, o *dataset* fornece as regiões de interesse (ROIs) recortadas e suas respectivas máscaras de segmentação binária representando o tumor. No contexto deste trabalho, as máscaras foram usadas para delimitar a área de extração das características radiômicas.

A distribuição detalhada das imagens utilizadas para o treinamento e teste dos modelos computacionais está apresentada na Tabela 1.

Table 1: Distribuição das imagens da base de dados CBIS-DDSM em tipo de treino ou teste.

Conjunto	Total	Benigno	Maligno
Treino	1318	681	637
Teste	378	231	147

2.2 Pré processamento

A fim de melhorar a extração de características, foram realizadas pré processamento das imagens do banco de dados. Nesse processo, diferentes métodos foram avaliadas, mas destacando o Filtro Bilateral e a Equalização de Histograma Adaptativo Limitada por Contraste (CLAHE) com maiores desempenhos preditivos:

- Filtro Bilateral: realiza a preservação de bordas e diminuição de ruído a partir da média ponderada da imagem
- Contrast Limited Adaptive Histogram Equalization (clahe): melhora o contraste da imagem a partir da equalização do histograma

2.3 Extração de Características com ResNet50

A *ResNet50* é uma Rede Neural Convolucional (CNN) composta por 50 camadas, amplamente utilizada para a extração de padrões visuais complexos. Neste trabalho, a rede foi aplicada aos recortes das Regiões de Interesse.

Para permitir a extração de características, as imagens passaram por uma etapa de pré-processamento. Este procedimento incluiu a conversão para o espaço de cores RGB, o redimensionamento para 224×224 pixels, junto a normalização de cor e brilho.

Para permitir a identificação de padrões, a *ResNet50* foi pré treinada coms o banco de dados da *ImageNet*, possibilitando a identificação de atributos visuais nas mamografias. Para extrair exclusivamente os vetores de características, foi alterado o resultado da CNN, alterando a última camada de classificação por uma função de identidade, que retorna apenas o vetor.

Por fim, os vetores resultantes foram associados aos identificadores únicos de cada imagem e encaminhados para a etapa de treinamento e previsão dos modelos computacionais.

2.4 Extração de Características Radiômicas

A extração de características radiômicas foi realizada com a biblioteca *pyradiomics*, uma ferramenta que quantifica atributos das imagens a partir de Regiões de Interesse (ROIs).

Para este proceso, cada mamografia foi processada em conjunto com sua respectiva máscara de segmentação binária, o qual delimita a área exata do tumor analisada. Para o extrator do *pyradiomics* foram definidos as configurações de normalização de intensidade, interpolação via *B-Spline* com *binWidth* de 25.

A partir dessa extração, foram extraídas métricas quantitativas da área tumoral. Esses atributos formaram vetores de características que foram associados aos identificadores únicos de cada imagem e encaminhados para a etapa de treinamento e previsão dos modelos computacionais.

2.5 Modelos: SVM e *Random Forest*

Para avaliar as características extraídas, os vetores resultantes dos conjuntos de treinamento foram colocados de entrada a dois algoritmos de aprendizado de máquina. Nesta etapa, foi necessário treinar com os dados de treino para a classificação das imagens mamográficas em duas categorias: benigno ou maligno, validando a eficiência depois com o conjunto de teste.

Os modelos selecionados para esta momento foram o *Support Vector Machine* (SVM) e o *Random Forest* (RF). O SVM, tiveram os parâmetros ajustados com erro em $C = 2.0$ e o coeficiente do *kernel* γ (*gamma*) configurado como *'scale'*.

Também, aplicou-se o *Random Forest*, um método de aprendizado de máquina que opera construindo múltiplas árvores de decisão. O modelo foi configurado com 100 estimadores.

3 Resultados

Para definir o desempenho dos modelos de predição, foi avaliado o conjunto de teste e os resultados da matriz confusão de cada caso estudado, resultando em verdadeiros positivos (VP), falsos positivos (FP), falsos negativos (FN) e verdadeiros negativos (VN). A partir dos dados anteriores foram calculadas métricas adicionais para determinar eficiência:

- Acurácia: proporção de acertos em relação ao total de casos;
- Sensibilidade: capacidade do modelo em identificar os casos belignos;
- Precisão: proporção de predições positivas que estavam corretas;
- F1-Score: média entre Sensibilidade e Precisão. O qual determina o melhor modelo em desempenho geral.

3.1 Desempenhos de todos os modelos

A tabela 2 mostra todos os resultados dos datasets com os dois modelos de predição.

Modelo	Acurácia	Sensib.	Precisão	F1-Score
SVM ResNet50	0.70	**0.63**	0.62	0.62
SVM Radiômica	0.60	0.45	0.48	0.46
SVM Mesclado	**0.71**	**0.63**	**0.63**	**0.63**
RF ResNet50	0.69	0.56	0.60	0.58
RF Radiômica	0.59	0.50	0.47	0.48
RF Mesclado	0.69	0.60	0.59	0.60

Table 2: Desempenho dos modelos preditivos com os conjuntos de características

Como observado na tabela 2, o modelo com extração de dados mesclado (radiômica e ResNet50) com o modelo de predição SVM teve os melhores resultados em todas as métricas. Enquanto isso, o modelo de *SVM Radiômica* tiveram os piores resultados em todas as métricas analisadas.

3.2 Pré processamento

Para fins de melhoramento de desempenho e métricas, foram analisadas dois casos específicos:

(1) Figura 1: Imagens sem pré processamento, além do necessário, como segmentação e redimensionamento de tamanho
(2) Figura 2: Imagens pré processadas como descrito na seção 2.2

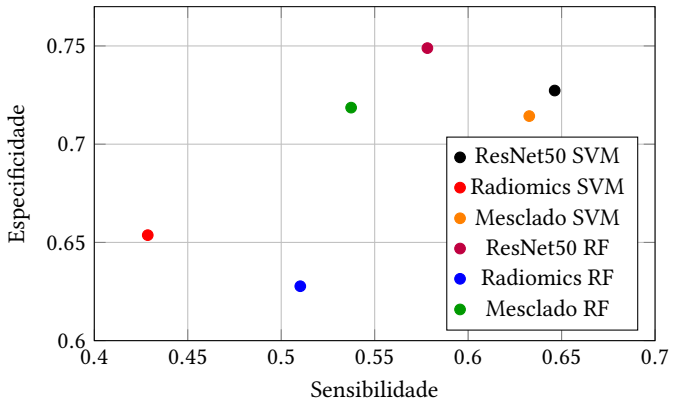


Figure 1: Relação entre sensibilidade e especificidade com imagens sem pré processamento

Observando a figura 1 concluimos que a ResNet50 SVM e o Mesclado SVM apresentam melhor equilibrio entre sensibilidade e especificidade.

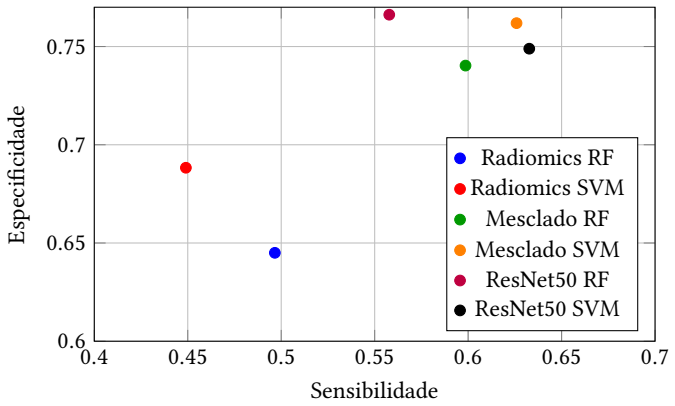


Figure 2: Relação entre sensibilidade e especificidade com imagens pré processadas

Nota-se o aumento na especificidade do ResNet50 SVM e Mesclado SVM se comparada a figura 1, onde os mesmos modelos se mantém com o equilibrio.

3.3 Comparação de extratores de dados

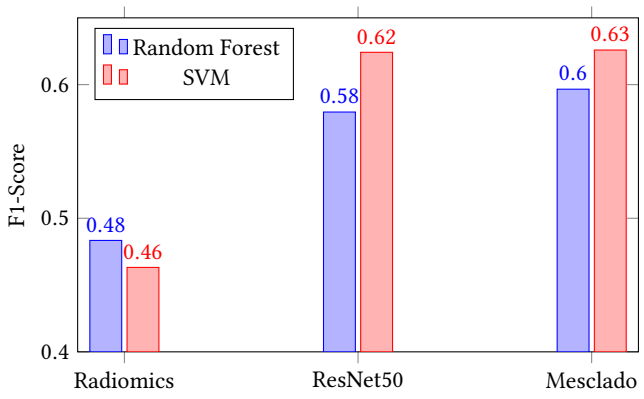


Figure 3: Comparação de F1-Score entre Random Forest e SVM com imagens pré processadas

A Figura 3 apresenta a comparação de F1-Score entre diferentes vetores de características usados nos modelos (radiômica, resnet e mesclado). É perceptível que o mesclado apresenta melhores métricas (0.63 no melhor dos casos), enquanto o de radiômica apresenta os piores resultados (sendo 0.46 o pior resultado).

Apesar desses resultados, também é importante ressaltar que o preditor *SVM* apresenta melhores resultados que o *Random Forest* em dois casos (ResNet50 e mesclado), mas aponta ser pior no caso da radiômica.

3.4 Acurácia entre diferentes contextos

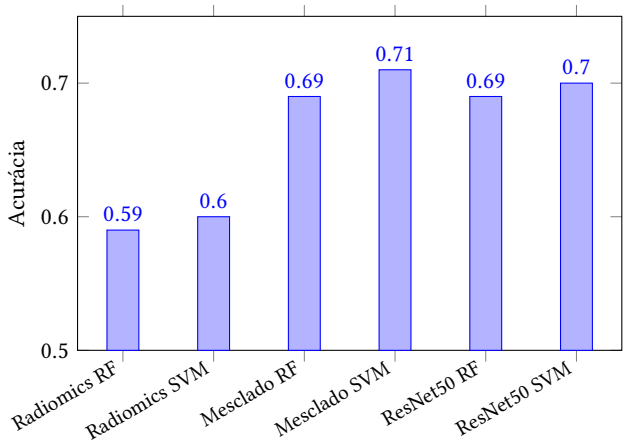


Figure 4: Comparação de acurácia entre diferentes abordagens

A figura 4 apresenta a comparação de acurácia em diferentes vetores de características e modelos de predição. A acurácia nesses casos mede a taxa de acerto da predição, benigno e maligno predito da forma correta. Nesses casos, os modelos não radiômicos exclusivos apresentam uma acurácia superior a 0.69, enquanto os modelos radiômics RF e SVM apresentam acurácia inferior a 0.61

3.5 Matriz confusão

A matriz confusão é uma forma de visualizar os casos totais de verdadeiros positivos e negativos, e falsos negativos e positivos.

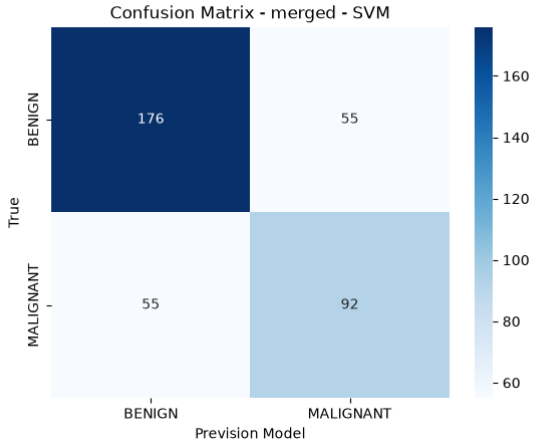


Figure 5: Matriz de confusão do modelo SVM com mesclado

A figura 5 apresenta a matriz confusão do Modelo SVM com vetor de características mesclado, o qual tem os melhores resultados gerais de métricas. Apresentando alta taxa de acerto, como acurácia.

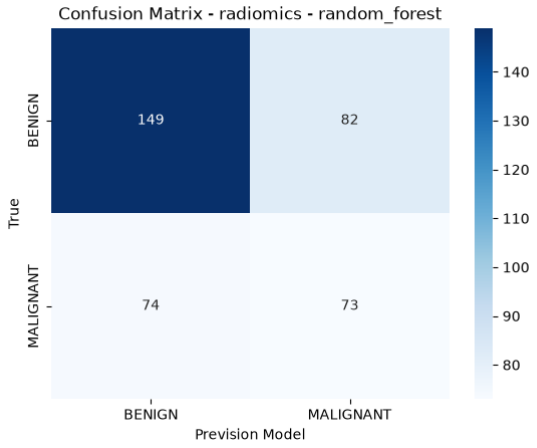


Figure 6: Matriz de confusão do modelo Random Forest com radiômica

Por último, a figura 6 apresenta a matriz confusão do modelo Random Forest com o vetor de características da radiômica, o qual tem os resultados inferiores das análises,

4 Discussão

Os resultados indicam que tanto o classificador quanto o tipo de características extraídas influenciam diretamente o desempenho

do modelo. O melhor resultado foi obtido pelo SVM com vetor mesclado (ResNet50 + radiômica) após pré-processamento, com acurácia de 0,7090 e F1-Score de 0,6259. Apesar disso o SVM com ResNet50 obteu resultados semelhantes, com acurácia de 0.7037 e F1-Score de 0.6242.

A fusão de características trouxe mudanças leves, aumentando a especificidade (0,7489 para 0,7619), mas com pequena redução na sensibilidade (0,6327 para 0,6259), para o modelo SVM com ResNet50. Esse ganho indica que a fusão não influenciou fortemente o modelo, indicando uma possível redundância de informações, em que os padrões da rede neural e as métricas radiômicas mapeiam características semelhantes da lesão, trazendo a problemática do tempo de processamento elevado para a radiômica, que nesse caso de estudo indica que é insuficiente dado aos resultados do ResNet50.

Já os modelos baseados apenas em características radiômicas apresentaram o pior desempenho, com F1-Score de 0,4632 para SVM e 0,4834 para Random Forest, e baixa sensibilidade (0,4490 para SVM e 0,4966 para Random Forest), indicando que essas features, isoladamente, não capturam adequadamente a complexidade das lesões sem apoio de representações mais profundas da ResNet50.

Além disso, o tamanho do dataset de treino ser pequeno, auxilia que mecanismos computacionais de predição, como o Random Forest e o SVM não apresentem dados tão precisos, vistos que existem casos de análise e decisões que não foram tão aprofundados nesse aprendizado de máquina limitado.

Por fim, o desbalanceamento da base de teste (231 casos benignos e 147 malignos) ajuda a explicar a diferença entre especificidade e sensibilidade. Isso indica a necessidade de técnicas adicionais de balanceamento de classes e melhorias na segmentação para tornar o modelo mais adequado para uso em apoio diagnóstico.

5 Conclusão

Neste trabalho, foram avaliadas diferentes abordagens para classificação de imagens de câncer de mama utilizando a base CBIS-DDSM, com extração de características por ResNet50 e radiômica, além de classificação com SVM e Random Forest e estratégias de pré-processamento.

Os resultados indicam que a combinação de características apresentou o melhor desempenho geral, enquanto o modelo baseado apenas em radiômica teve o pior desempenho entre as abordagens testadas. Entre os classificadores, o SVM se destacou em relação ao Random Forest nos experimentos realizados.

É importante destacar que os experimentos foram conduzidos com um conjunto de 1318 imagens, o que pode ser considerado relativamente limitado para problemas de classificação de imagens médicas, especialmente quando se utilizam modelos com alta capacidade de representação (ResNet50 por exemplo). Além disso, o desempenho obtido pode ser sensível à segmentação dos nódulos e às escolhas de pré-processamento, o que pode influenciar diretamente as métricas finais.

De forma geral, observa-se que a escolha do tipo de característica e do classificador influencia diretamente no desempenho do modelo, reforçando a importância dessas etapas no problema abordado, que apesar do valor máximo de acurácia de 0.71, já apresenta um bom resultado para fins de auxílio de diagnóstico, mesmo com quantidade de dados de tamanho limitado. Apesar que deve ser evitado ao uso de casos reais, visto as quantidades grandes de falsos negativos e positivos em todas análises feitas.